성능 올리기 모험기

작성 이유

처음에 직접 판단하며 Functioning day 칼럼을 부활시켜 한방에 성능을 88에서 94까지 올렸지만,

이후 모델의 성적을 위해, AI가 시키는대로만 따라가는 것 같아(물론 점수는 올랐지만) 해당 모델을 포기하고,

진짜 학습을 하고자 함. 그리고 기억력 이슈로 ppt로 정리

모델 3총사가 예측한 값과 실제 값을 비교해서 오차가 큰 Top20을 내도록 지시

수상하게 1개도 안 빌린 날이 존재.

🔍 [DecisionTree] 핵심 오차 분석 (이진 컬럼 제외 / 원본 단위 복원):

	Actual	Predicted	Error	Hour	Temperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (mm)	month	weekend	WEP (mm)
1694	0	2455.0	2455.0	19.0	23.2	57.0	2.2	2000.0	14.2	0.03	0.0	0.0	9.0	0.0	0.0
641	0	2349.0	2349.0	17.0	21.7	52.0	1.1	2000.0	11.4	0.79	0.0	0.0	9.0	0.0	0.0
1189	2276	0.0	2276.0	8.0	18.9	77.0	0.6	1109.0	14.7	0.56	0.0	0.0	9.0	0.0	0.0
1044	0	2170.0	2170.0	15.0	25.9	39.0	1.4	1836.0	10.8	0.90	0.0	0.0	9.0	0.0	0.0
384	2112	0.0	2112.0	16.0	24.0	34.0	2.7	2000.0	7.1	1.62	0.0	0.0	10.0	0.0	0.0
695	2065	0.0	2065.0	21.0	17.7	63.0	0.5	1324.0	10.5	0.00	0.0	0.0	5.0	0.0	0.0
1134	2012	0.0	2012.0	21.0	23.2	57.0	1.1	2000.0	14.2	0.00	0.0	0.0	9.0	0.0	0.0
774	0	1922.0	1922.0	8.0	13.5	63.0	2.2	1211.0	6.5	1.01	0.0	0.0	5.0	0.0	0.0
1049	0	1877.0	1877.0	15.0	21.3	32.0	3.8	2000.0	3.9	2.31	0.0	0.0	9.0	1.0	0.0
1458	0	1870.0	1870.0	17.0	25.0	44.0	1.3	1883.0	11.8	0.36	0.0	0.0	9.0	0.0	0.0
1246	0	1678.0	1678.0	16.0	25.6	41.0	1.2	1594.0	11.3	0.65	0.0	0.0	9.0	0.0	0.0
910	2154	477.0	1677.0	18.0	23.1	68.0	2.9	1506.0	16.8	0.42	0.0	0.0	5.0	0.0	0.0
1391	2134	477.0	1657.0	18.0	18.9	68.0	3.3	1326.0	12.8	0.12	0.0	0.0	4.0	0.0	0.0
986	2082	440.0	1642.0	8.0	11.8	80.0	3.7	1518.0	8.4	0.16	0.0	0.0	10.0	0.0	0.0
1606	1604	0.0	1604.0	17.0	15.7	63.0	3.2	1118.0	8.6	0.39	0.0	0.0	10.0	0.0	0.0
9	0	1579.0	1579.0	15.0	18.5	25.0	1.6	1724.0	-1.9	1.63	0.0	0.0	11.0	1.0	0.0
760	0	1577.0	1577.0	16.0	26.4	34.0	2.5	1953.0	9.2	1.60	0.0	0.0	9.0	0.0	0.0
979	699	2202.0	1503.0	10.0	9.4	55.0	0.1	570.0	0.7	0.49	0.0	0.0	11.0	0.0	0.0
680	0	1501.0	1501.0	22.0	15.5	69.0	0.8	1987.0	9.8	0.00	0.0	0.0	10.0	0.0	0.0
1640	657	2149.0	1492.0	7.0	19.4	69.0	0.3	1277.0	13.5	0.42	0.0	0.0	6.0	0.0	0.0

가설

모델이 0을 아예 예상하지 못한 게 아닐까?

예상은 몇 천 개를 해놓고, 막상 실제값은 0

혹시 오류인가 싶어 데이터를 직접 보니까 서비스 점검(Functioning day) 존재 확인

[DecisionTree] 핵심 오차 분석 (미진

	Actual	Predicted	Error	Hour
1694	0	2455.0	2455.0	19.0
641	0	2349.0	2349.0	17.0
1189	2276	0.0	2276.0	8.0
1044	0	2170.0	2170.0	15.0
384	2112	0.0	2112.0	16.0
695	2065	0.0	2065.0	21.0
1134	2012	0.0	2012.0	21.0

1개도 안 빌린 날(0개)을 구분하기 위해, 제외한 Functioning day 부활.

```python
# S2P2 colab(3) 데이터 시각화에서 했던 feature_engineering 적용하는 함수 지정

def feature_engineering(df):
  df_fe = df.copy()
  # Date 월, 요일, 주말여부
  df_fe['Date'] = pd.to_datetime(df_fe['Date'], format='%d/%m/%Y')
  df_fe['month'] = df_fe['Date'].dt.month
  df_fe['dayname'] = df_fe['Date'].dt.day_name()
  df_fe['weekend'] = (df_fe['Date'].dt.weekday >= 5).astype(int)

  # 칼럼 단위 변환
  df_fe['Snowfall (cm)'] = df_fe['Snowfall (cm)'] / 10
  df_fe.rename(columns={'Snowfall (cm)': 'Snowfall (mm)'}, inplace=True)

  # WEP (mm) 칼럼 추가
  df_fe['WEP (mm)'] = df_fe['Rainfall(mm)'] + df_fe['Snowfall (mm)']

  # 시간대 카테고리 생성
  bins = [-1, 5, 11, 17, 23]
  labels = ['Dawn(0~5)', 'Morning(6~11)', 'Afternoon(12~17)', 'Evening(18~23)']
  df_fe['Hour_cat'] = pd.cut(df_fe['Hour'], bins=bins, labels=labels)

  # Date, id, Functioning Day 칼럼 제거 - 데이터 누수 방지, 불필요칼럼 제거
  # df_fe = df_fe.drop(['Date', 'id', 'Functioning Day'], axis=1)
  df_fe = df_fe.drop(['Date', 'id'], axis=1)

  return df_fe
```

```python
# 데이터셋 전처리 함수

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder
from sklearn.preprocessing import StandardScaler

def preprocessing(train_df, test_df, test_size=0.25, random_state=42, drop_cols=True):
  # 1) df복사 및 불필요 칼럼 삭제
  train2 = train_df.copy()
  test2  = test_df.copy()
  if drop_cols:
    # train2 = train2.drop(['Date', 'id', 'Functioning Day'], axis=1)
    # test2  = test2.drop(['Date', 'id', 'Functioning Day'], axis=1)
    train2 = train2.drop(['Date', 'id'], axis=1)
    test2  = test2.drop(['Date', 'id'], axis=1)
```

Functioning day를 부활시킨 것만으로 높은 상승

Actual도 0이 없어짐

```
basic
Decision Tree
RMSE: 408.225
R2: 0.592
------------------------------
Random Forest
RMSE: 309.308
R2: 0.766
------------------------------
XGBoost
RMSE: 308.940
R2: 0.766
------------------------------
EDA
Decision Tree
RMSE: 359.640
R2: 0.683
------------------------------
Random Forest
RMSE: 259.342
R2: 0.835
------------------------------
XGBoost
RMSE: 231.239
R2: 0.869
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 239.153
R2: 0.860
------------------------------
EDA
Decision Tree
RMSE: 267.686
R2: 0.825
------------------------------
Random Forest
RMSE: 182.676
R2: 0.918
------------------------------
XGBoost
RMSE: 159.015
R2: 0.938
------------------------------
```

[DecisionTree] 핵심 오차 분석 (이진 컬럼 제외 / 원본 단위 복원):

	Actual	Predicted	Error	Hour	Temperature(° C)	Humi
632	234	2329.0	2095.0	15.0	19.6	
1198	513	2202.0	1689.0	9.0	8.6	
910	2154	477.0	1677.0	18.0	23.1	
41	3556	1935.0	1621.0	18.0	24.1	
1642	589	2202.0	1613.0	8.0	9.3	
170	524	2129.0	1605.0	8.0	14.1	
1250	384	1987.0	1603.0	14.0	20.7	
1292	589	2101.0	1512.0	8.0	14.6	
256	579	2068.0	1489.0	8.0	14.4	

Feature Importance

임포턴스에서도 잘 올라온 걸 볼 수 있다

```
models = [dt, rf, xgb]
names = ["Decision Tree", "Random Forest", "XGBoost"]

plot_feature_importance_subplot(models, X_tr_EDA, names)
```

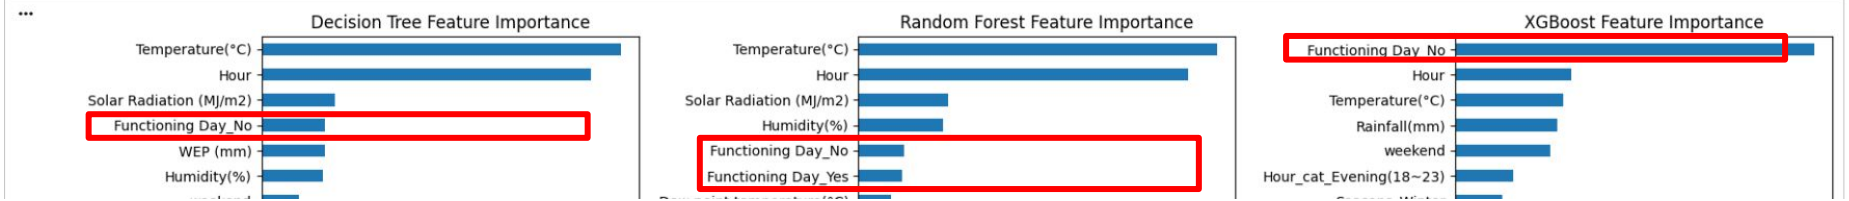

Permutation Importance

XGB가 이걸 가장 중요하게 보고 있다 이유가 뭘까

어떤 건 비중이 적고 어떤 건 높은 이유가 뭘까

```
models = [dt, rf, xgb]
names = ["Decision Tree", "Random Forest", "XGBoost"]

plot_permutation_importance_subplot(models, X_va_EDA, y_val, names)
```

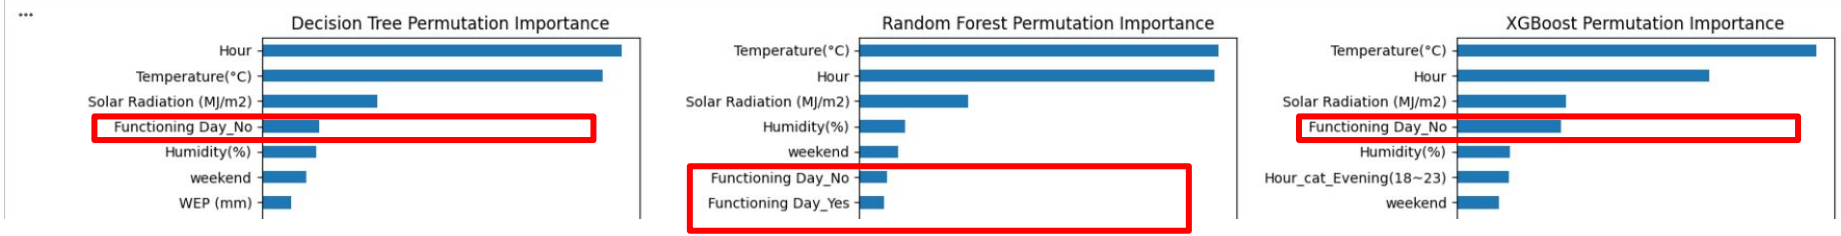

가설

Functioning day가 고유ID와 같은 역할을 하는 것이 아닐까? 컨닝은 하면 안 되지
생각에는 모델에게 0으로 찍히는 날도 있다고 주의해주는 것 같기도 하고,
그렇다면 아닌 것 같은데, 모르겠다

마스터님께서 답변해주시기를 , 사실 Functioning day 변수는 대여량에 도움이 안 되는 변수기도 하고, 실습 목적과 달라서 일부러 지우셨다고 한다.

그리고 데이터 누수에 해당한다고는 하셨다

중대 발표

Functioning day는 사실 대여량과 관련이 없고, 실습에 방해될 수 있는 조건이어따!

따라서 데이터에서 해당 변수를 제외하고 다시 시작하게따

라고 했지만 다시 하라고 하셔따

Feature Importance FI 는 공부할 때 얼마나 봤는지

```
models = [dt, rf, xgb]
names = ["Decision Tree", "Random Forest", "XGBoost"]

plot_feature_importance_subplot(models, X_tr_EDA, names)
```

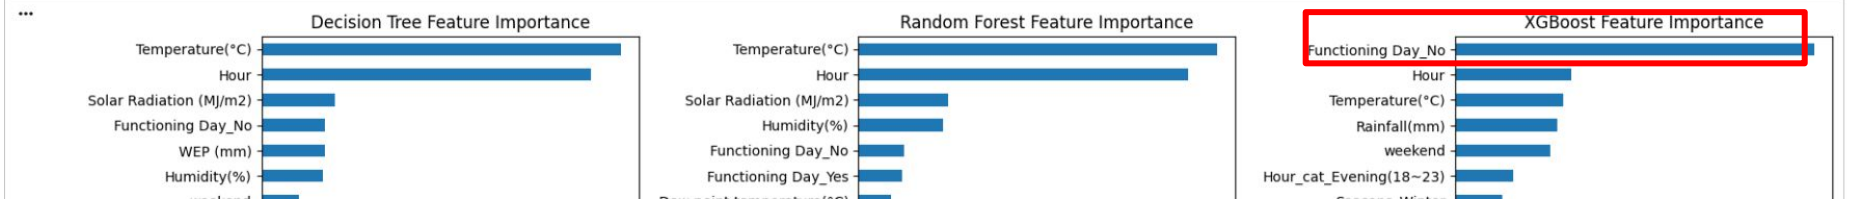

Permutation Importance PI는 시험 쳤을 때 뭐가 중요했는지

```
models = [dt, rf, xgb]
names = ["Decision Tree", "Random Forest", "XGBoost"]

plot_permutation_importance_subplot(models, X_va_EDA, y_val, names)
```

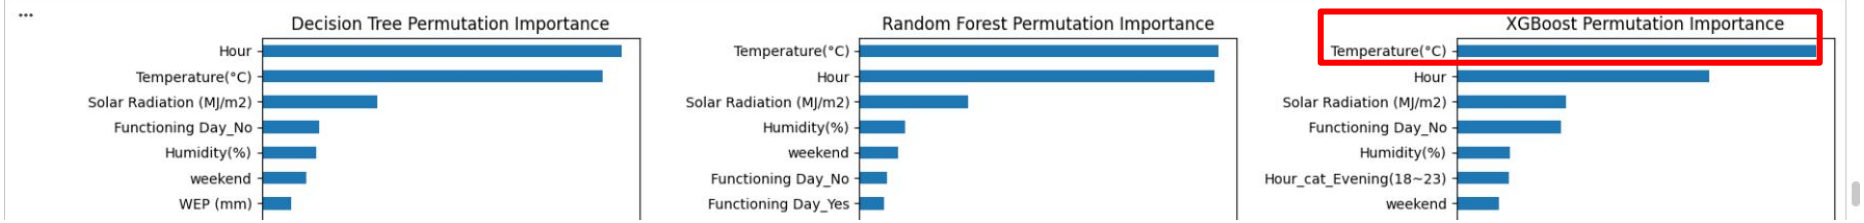

가설

XGB에서 공부는 점검일 변수로 했는데, 막상 시험은 온도가 더 중요했다

다른 애들처럼 온도를 더 공부하면 안 되겠니, 점검일이 이진법이라 외울 게 없어서 더 쉬웠니

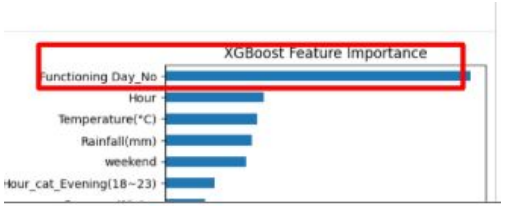

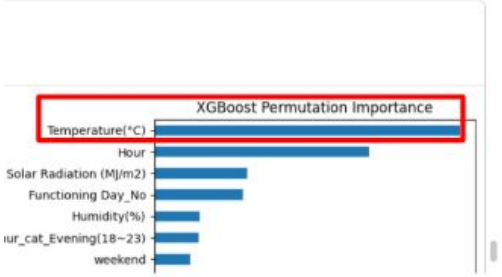

점검일 변수가 실제로 얼마나 비중을 차지하는지 확인할 수 있는 코드 지시

```
X_tr_EDA['Functioning Day_Yes'].value_counts(normalize=True)
```

...

Functioning Day_Yes	proportion
1.0	0.966705
0.0	0.033295

dtype: float64

3.3%밖에 안 되는 문제 풀려고
그 부분만 계속 공부하고 있던 것 확인

XGB의 파라미터를 조정

```
# xgb = XGBRegressor(n_estimators=100, n_jobs=-1, random_state=42)
xgb = XGBRegressor(colsample_bytree=0.7,learning_rate=0.05, n_estimators=1000, n_jobs=-1, random_state=42)
```

XGB의 파라미터를 조정

colsample_bytree로 나무 만들 때 70%의 변수만 사용하도록
learning_rate로 더 꼼꼼히 보게
n_estimators를 1000개로 해서 10배 많이

XGB가 올랐다

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 239.153
R2: 0.860
------------------------------
EDA
Decision Tree
RMSE: 267.686
R2: 0.825
------------------------------
Random Forest
RMSE: 182.676
R2: 0.918
------------------------------
XGBoost
RMSE: 159.015
R2: 0.938
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 267.686
R2: 0.825
------------------------------
Random Forest
RMSE: 182.676
R2: 0.918
------------------------------
XGBoost
RMSE: 151.620
R2: 0.944
------------------------------
```

Feature Importance

이번엔 weather index가 엄청 올랐다

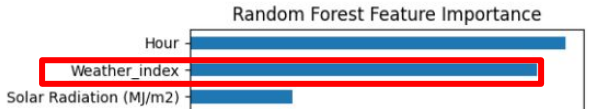

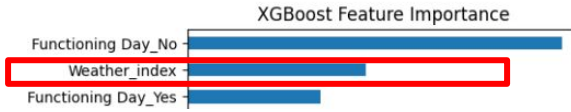

Permutation Importance

PI에서도 마찬가지

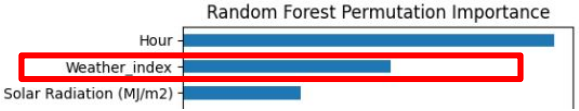

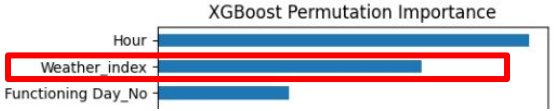

weather index가 없어도 점수가 같을까?

EDA 부분에서 오히려 올랐다

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 267.686
R2: 0.825
------------------------------
Random Forest
RMSE: 182.676
R2: 0.918
------------------------------
XGBoost
RMSE: 151.620
R2: 0.944
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 246.221
R2: 0.852
------------------------------
Random Forest
RMSE: 177.473
R2: 0.923
------------------------------
XGBoost
RMSE: 148.953
R2: 0.946
------------------------------
```

Feature Importance

Permutation Importance

PI에서도 마찬가지

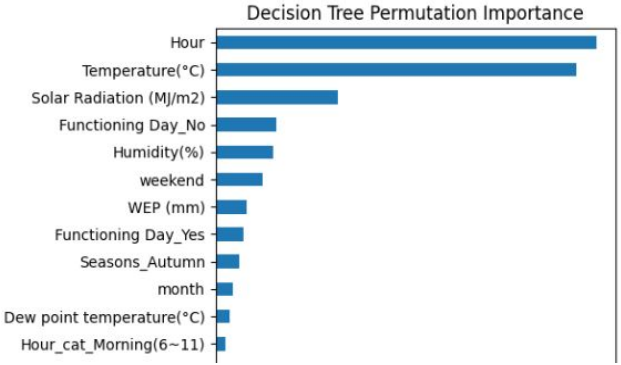

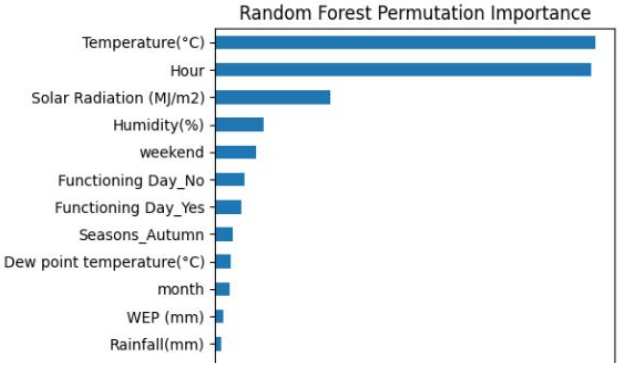

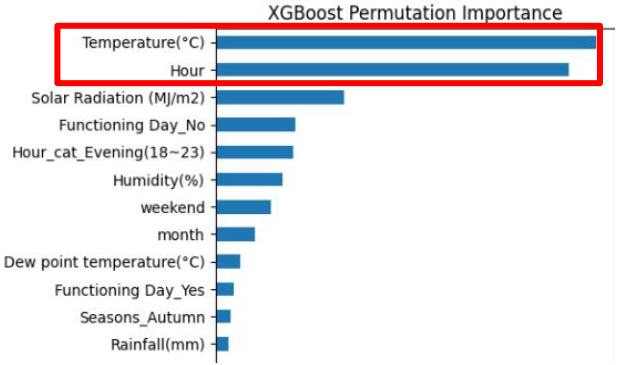

보니까 아까 weather index가 하단에 있어서, 상단에서는 변수에 적용이 안 됐던 것 같다

중요한 점은, XGB 이놈이 점검일을 엄청나게 보고 있다 (물론 좋은 정보고, 핵심 정보이긴하다)

아이디어를 내기 위해 다시 표를 봐보자 일단 이건 XGB다

주말인 경우, 일단 더 많이 빌렸다
출근 시간대엔 많이 빌렸다
새벽엔 덜 빌렸다

🔍 [XGBoost] 핵심 오차 분석 (이진 컬럼 제외 / 원본 단위 복원):

	Actual	Predicted	Error	Hour	emperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (mm)	month	eekend	EP (mm)
1237	1058	2235.709961	1177.71	19.0	25.7	47.0	1.8	2000.0	13.5	0.04	0.0	0.0	6.0	1.0	0.0
1417	600	1731.000000	1131.00	8.0	14.8	80.0	0.3	1921.0	11.3	0.31	0.0	0.0	5.0	0.0	0.0
1250	384	1359.260010	975.26	14.0	20.7	32.0	1.5	1996.0	3.3	0.69	0.0	0.0	4.0	1.0	0.0
1683	103	1020.900024	917.90	16.0	19.1	52.0	0.9	1583.0	9.0	0.37	0.0	0.0	4.0	1.0	0.0
1640	657	1483.349976	826.35	7.0	19.4	69.0	0.3	1277.0	13.5	0.42	0.0	0.0	6.0	0.0	0.0
785	389	1136.650024	747.65	7.0	14.2	81.0	0.3	1991.0	10.9	0.13	0.0	0.0	5.0	0.0	0.0
1541	3016	2290.540039	725.46	18.0	27.5	77.0	2.1	1897.0	23.0	0.46	0.0	0.0	7.0	0.0	0.0
486	2474	1754.010010	719.99	16.0	25.8	50.0	1.7	1152.0	14.5	0.66	0.0	0.0	6.0	0.0	0.0
1395	542	1260.170044	718.17	21.0	10.6	70.0	2.4	2000.0	5.3	0.00	0.0	0.0	10.0	0.0	0.0
1585	1254	538.229980	715.77	2.0	20.9	87.0	1.8	222.0	18.6	0.00	0.0	0.0	6.0	1.0	0.0
1407	575	1265.989990	690.99	9.0	21.1	72.0	1.0	1982.0	15.8	0.52	0.0	0.0	7.0	0.0	0.0
596	1259	1949.510010	690.51	21.0	24.7	61.0	1.6	2000.0	16.6	0.00	0.0	0.0	9.0	0.0	0.0
1147	208	898.419983	690.42	8.0	16.9	72.0	1.3	2000.0	11.8	0.04	0.3	0.0	10.0	0.0	0.3
928	670	1332.089966	662.09	8.0	20.7	73.0	0.8	2000.0	15.6	0.30	0.2	0.0	7.0	0.0	0.2
811	827	1472.510010	645.51	8.0	25.1	97.0	0.8	490.0	24.5	0.26	0.0	0.0	7.0	0.0	0.0
1455	1276	1882.280029	606.28	21.0	22.5	65.0	1.1	2000.0	15.5	0.00	0.0	0.0	8.0	1.0	0.0
399	385	990.729980	605.73	16.0	12.2	65.0	1.9	2000.0	5.8	0.52	0.0	0.0	10.0	1.0	0.0
1717	1223	1818.290039	595.29	16.0	23.2	30.0	4.5	1787.0	4.6	1.49	0.0	0.0	5.0	1.0	0.0
632	234	821.190002	587.19	15.0	19.6	44.0	2.4	1885.0	7.0	0.47	0.2	0.0	4.0	1.0	0.2
310	1289	704.099976	584.90	7.0	20.1	97.0	1.9	443.0	19.6	0.03	0.0	0.0	9.0	0.0	0.0

우선 뭉뚱그려 칼럼을 만들어봤다

```
# Date, id, Functioning Day 칼럼 제거 - 데이터 누수 방지, 불필요칼럼 제거
# df_fe = df_fe.drop(['Date', 'id', 'Functioning Day'], axis=1)
df_fe = df_fe.drop(['Date', 'id'], axis=1)

# 1. 출퇴근 시간대 (평일 7~9시, 17~20시)
df_fe['Is_Commute'] = ((df_fe['weekend'] == 0) &
                       ((df_fe['Hour'].between(7, 9)) | (df_fe['Hour'].between(17, 20)))).astype(int)

# 2. 주말 피크 시간대 (주말 10~18시)
df_fe['Is_Weekend_Peak'] = ((df_fe['weekend'] == 1) &
                            (df_fe['Hour'].between(10, 18))).astype(int)

# 3. 온도와 습도의 불쾌지수 (자전거 타기 좋은 날씨인지)
# 기온과 습도가 높을 때 대여량이 급감하는 현상 반영
df_fe['Discomfort_Index'] = 0.81 * df_fe['Temperature(° C)'] + ₩
                            0.01 * df_fe['Humidity(%)'] * (0.99 * df_fe['Temperature(° C)'] - 14.3) + 46.3
return df_fe
```

출퇴근 시간대, 주말 피크 시간대, 불쾌지수 추가

Feature Importance

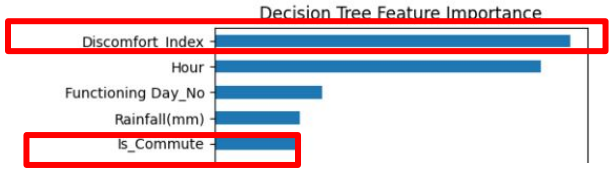

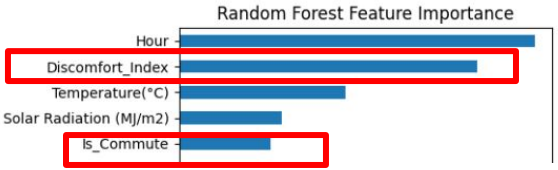

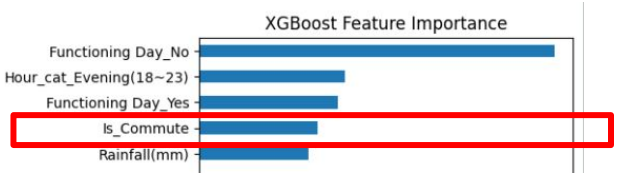

Permutation Importance

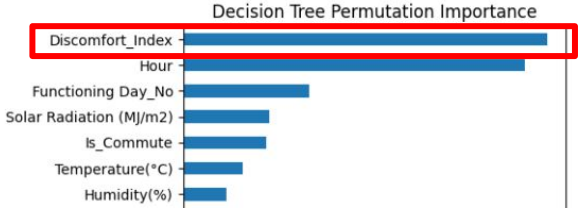

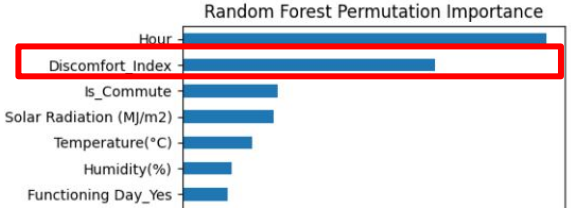

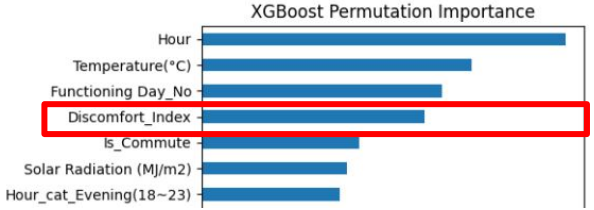

불쾌지수가 많이 올라갔다

XGB에서는 출퇴근 시간대를 더 학습하고, 불쾌지수는 올라오지 않았다

여전히 Hour는 지배적이다

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 246.221
R2: 0.852
------------------------------
Random Forest
RMSE: 177.473
R2: 0.923
------------------------------
XGBoost
RMSE: 148.953
R2: 0.946
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 244.053
R2: 0.854
------------------------------
Random Forest
RMSE: 173.421
R2: 0.926
------------------------------
XGBoost
RMSE: 150.177
R2: 0.945
------------------------------
```

XGB가 떨어지고, 다른 게 올랐다

영 만족스럽지 않다

이번엔 출퇴근 시간과 새벽 시간 변수를 추가했지만, 성능은 오르지 않았다

🔍 [XGBoost] 핵심 오차 분석 (이진 컬럼 제외 / 원본 단위 복원):

	Actual	Predicted	Error	Hour	Temperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (mm)	month	weekend	WEP (mm)	Is_RushHour	Is_QuietTime
1237	1058	2221.669922	1163.67	19.0	25.7	47.0	1.8	2000.0	13.5	0.04	0.0	0.0	6.0	1.0	0.0	1.0	0.0
1417	600	1725.859985	1125.86	8.0	14.8	80.0	0.3	1921.0	11.3	0.31	0.0	0.0	5.0	0.0	0.0	1.0	0.0
1683	103	1086.349976	983.35	16.0	19.1	52.0	0.9	1583.0	9.0	0.37	0.0	0.0	4.0	1.0	0.0	-0.0	0.0
876	163	1110.040039	947.04	15.0	21.1	72.0	2.7	663.0	15.8	0.31	0.1	0.0	5.0	0.0	0.1	-0.0	0.0
1250	384	1253.880005	869.88	14.0	20.7	32.0	1.5	1996.0	3.3	0.69	0.0	0.0	4.0	1.0	0.0	-0.0	0.0
1640	657	1490.959961	833.96	7.0	19.4	69.0	0.3	1277.0	13.5	0.42	0.0	0.0	6.0	0.0	0.0	1.0	0.0
785	389	1200.410034	811.41	7.0	14.2	81.0	0.3	1991.0	10.9	0.13	0.0	0.0	5.0	0.0	0.0	1.0	0.0

보면, 평균적으로 실제보다 훨씬 많이 예측한다
근데 저 날엔 왜 덜 빌렸을까? 온도가 높지도 않은데 말이다

직접 ID를 확인해봐야겠다

엥? 근데 지금 ID와 일치하지 않는다

```python
# [진단] 특정 ID의 원본 데이터 상세 조회 (날짜 포함)
target_id = 1237

print(f"--- [ID {target_id}] 원본 CSV 데이터 상세 정보 ---")
# df_train이 인덱스를 유지하고 있다면 loc으로 바로 조회 가능합니다.
if target_id in df_train.index:
    display(df_train.loc[[target_id]])
else:
    print("해당 ID가 원본 데이터에 존재하지 않습니다. 인덱스 확인이 필요합니다.")
```

```
--- [ID 1237] 원본 CSV 데이터 상세 정보 ---
```

	Date	Rented Bike Count	Hour	Temperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
1237	03/07/2018	2598	19	30.4	62	0.9	2000	22.2	0.65	0.1	0.0	Summer	No Holiday	Yes	12763

데이터를 가공할 때, 새 인덱스를 부여해서 그런 것 같다

그냥 빌린 자전거 대수로 확인해보도록 하자

범인을 검거한 것이다

```
# [원본 검색] 대여수가 2598대인 모든 행 찾기
target_count = 1058
display(df_train[df_train['Rented Bike Count'] == target_count])
```

	Date	Rented Bike Count	Hour	Temperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
359	15/05/2018	1058	12	26.3	36	1.1	1133	10.0	2.88	0.0	0.0	Spring	No Holiday	Yes	11474
3045	09/06/2018	1058	19	25.7	47	1.8	2000	13.5	0.04	0.0	0.0	Summer	No Holiday	Yes	15292
5027	05/06/2018	1058	13	28.6	34	2.0	1274	11.1	2.82	0.0	0.0	Summer	No Holiday	Yes	13404
6829	14/07/2018	1058	15	31.1	59	2.3	1929	22.1	2.34	0.0	0.0	Summer	No Holiday	Yes	13068

자전거 타기 아주 좋은 날로 보인다
18년 6월 9일은 평범한 토요일이다
모델은 왜 이 조건에 엄청 많이 빌릴 것이라 예상했을까?

다른 데이터를 확인해보았다

931	07/05/2018	600	8	14.8	80	0.3	1921	11.3	0.31	0.0	0.0	Spring	No Holiday	Yes	14261

달력정보

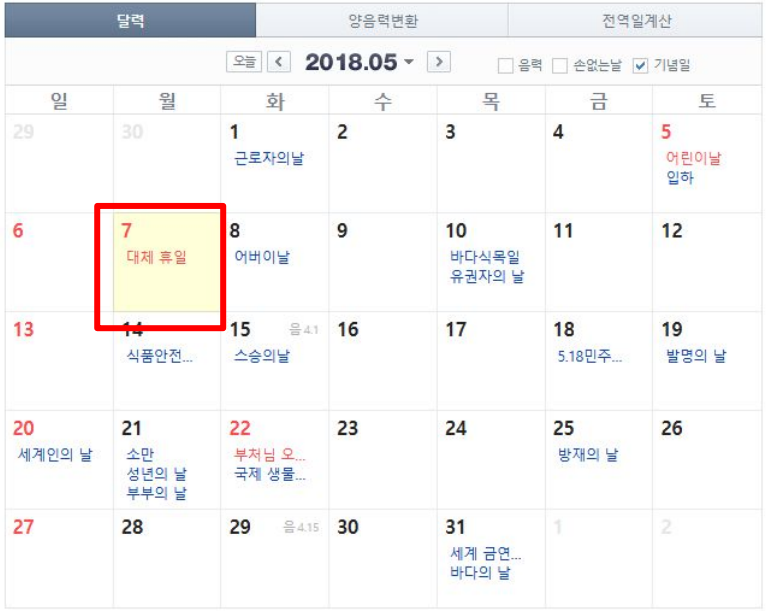

빨간날인데 왜 No Holiday일까?
대체 공휴일이라 그런가?

```
# 비율로 확인 (0.96, 0.03 등)
X_tr_EDA['Holiday_No Holiday'].value_counts(normalize=True)
```

...

Holiday_No Holiday	proportion
1.0	0.950342
0.0	0.049658

dtype: float64

Holiday가 있기는 하다. 아마 대체 공휴일이라 그럴 수 있다

혹시 이전 시간에 많이 빌렸나? 그것도 아니다

```
# 날짜 검색
target_count = '07/05/2018'
display(df_train[df_train['Date'] == target_count])
```

	Date	Rented Bike Count	Hour	Temperature(˚C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(˚C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
875	07/05/2018	2392	17	25.5	31	2.3	1974	7.1	1.50	0.0	0.0	Spring	No Holiday	Yes	16636
931	07/05/2018	600	8	14.8	80	0.3	1921	11.3	0.31	0.0	0.0	Spring	No Holiday	Yes	14261
1166	07/05/2018	1665	13	23.7	44	1.7	1897	10.7	2.35	0.0	0.0	Spring	No Holiday	Yes	11678
1440	07/05/2018	1336	22	18.6	69	1.7	1047	12.7	0.00	0.0	0.0	Spring	No Holiday	Yes	16382
1446	07/05/2018	737	9	15.9	72	0.5	1835	10.8	0.67	0.0	0.0	Spring	No Holiday	Yes	16254
1451	07/05/2018	1912	20	20.9	61	2.7	1523	13.0	0.01	0.0	0.0	Spring	No Holiday	Yes	14662
1508	07/05/2018	994	23	17.5	69	1.5	978	11.7	0.00	0.0	0.0	Spring	No Holiday	Yes	13442
1619	07/05/2018	1167	11	20.2	45	1.1	1894	7.8	2.33	0.0	0.0	Spring	No Holiday	Yes	17676
2532	07/05/2018	609	1	15.1	84	0.3	1858	12.4	0.00	0.0	0.0	Spring	No Holiday	Yes	14969
3378	07/05/2018	185	4	14.4	85	0.8	1437	11.9	0.00	0.0	0.0	Spring	No Holiday	Yes	16294
3455	07/05/2018	249	3	14.7	82	0.8	1822	11.6	0.00	0.0	0.0	Spring	No Holiday	Yes	12276
3712	07/05/2018	2268	18	25.1	32	2.4	1899	7.2	1.10	0.0	0.0	Spring	No Holiday	Yes	18020
4848	07/05/2018	895	10	17.5	63	0.6	1916	10.3	0.96	0.0	0.0	Spring	No Holiday	Yes	14630
5369	07/05/2018	1717	21	19.6	64	1.5	1297	12.5	0.00	0.0	0.0	Spring	No Holiday	Yes	14366
5516	07/05/2018	1414	12	22.9	35	0.8	1948	6.6	3.05	0.0	0.0	Spring	No Holiday	Yes	10807
5688	07/05/2018	2191	15	24.6	38	2.1	1478	9.3	1.85	0.0	0.0	Spring	No Holiday	Yes	15187
6023	07/05/2018	170	5	14.2	85	0.5	1412	11.7	0.00	0.0	0.0	Spring	No Holiday	Yes	12759
6232	07/05/2018	2213	16	24.5	38	2.2	1903	9.2	1.10	0.0	0.0	Spring	No Holiday	Yes	16474
6747	07/05/2018	389	7	14.2	81	0.3	1991	10.9	0.13	0.0	0.0	Spring	No Holiday	Yes	11070
6996	07/05/2018	221	6	14.0	87	0.8	1334	11.8	0.01	0.0	0.0	Spring	No Holiday	Yes	15801

있는 코드를 응용해서 찾아보았다

혹시 주말이면 11시부터 22시까지 많이 빌릴까? 다른 날짜도 봐본다

다음 주 일요일이다

```
# 날짜 검색
target_count = '13/05/2018'
display(df_train[df_train['Date'] == target_count])
```

	Date	Rented Bike Count	Hour	Temperature(˚C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(˚C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
56	13/05/2018	716	10	15.2	88	2.2	1090	13.2	0.55	0.0	0.0	Spring	No Holiday	Yes	17623
334	13/05/2018	2410	17	19.4	63	2.6	1099	12.1	1.61	0.0	0.0	Spring	No Holiday	Yes	10878
608	13/05/2018	1714	20	15.6	81	2.3	827	12.3	0.02	0.0	0.0	Spring	No Holiday	Yes	18030
748	13/05/2018	178	1	15.1	97	1.7	173	14.6	0.00	0.2	0.0	Spring	No Holiday	Yes	16086
1890	13/05/2018	139	6	13.5	98	0.4	251	13.1	0.01	0.0	0.0	Spring	No Holiday	Yes	12557
2287	13/05/2018	2023	19	17.6	73	2.0	886	12.6	0.34	0.0	0.0	Spring	No Holiday	Yes	18516
2451	13/05/2018	145	0	15.5	97	1.5	181	15.0	0.00	0.5	0.0	Spring	No Holiday	Yes	13073
2772	13/05/2018	1155	22	13.5	87	2.2	433	11.3	0.00	0.0	0.0	Spring	No Holiday	Yes	18209
3070	13/05/2018	993	11	16.4	78	1.6	1209	12.5	1.37	0.0	0.0	Spring	No Holiday	Yes	12919
3106	13/05/2018	579	9	14.8	95	1.0	986	14.0	0.53	0.0	0.0	Spring	No Holiday	Yes	14730
3553	13/05/2018	189	2	14.5	97	2.9	359	14.0	0.00	0.1	0.0	Spring	No Holiday	Yes	15782
3945	13/05/2018	83	4	13.8	98	2.9	27	13.4	0.00	0.0	0.0	Spring	No Holiday	Yes	15770
3982	13/05/2018	397	8	14.1	98	1.3	834	13.7	0.26	0.0	0.0	Spring	No Holiday	Yes	15604
4058	13/05/2018	814	23	13.0	89	1.3	326	11.2	0.00	0.0	0.0	Spring	No Holiday	Yes	18391
4897	13/05/2018	220	7	13.7	98	1.6	468	13.3	0.10	0.0	0.0	Spring	No Holiday	Yes	10885
5059	13/05/2018	72	5	13.5	98	0.8	105	13.1	0.00	0.0	0.0	Spring	No Holiday	Yes	16730
5328	13/05/2018	2329	15	19.7	63	2.5	941	12.4	2.01	0.0	0.0	Spring	No Holiday	Yes	17691
5556	13/05/2018	1571	21	14.1	86	0.9	535	11.7	0.00	0.0	0.0	Spring	No Holiday	Yes	15821
6053	13/05/2018	141	3	14.2	98	1.5	135	13.8	0.00	0.2	0.0	Spring	No Holiday	Yes	10922
6753	13/05/2018	2338	18	19.0	66	1.3	1111	12.4	0.95	0.0	0.0	Spring	No Holiday	Yes	14241
6804	13/05/2018	2379	16	19.5	65	2.9	857	12.7	1.97	0.0	0.0	Spring	No Holiday	Yes	12284

주말엔 11시까지는 거의 빌리지 않는다 대신 22시까지 양이 많아진다

그렇다면 주말과 오전 시간대에 영향을 주는 변수를 만들어 볼까?

근데 여기도 Holiday가 아니다, 뭐가 Holiday지?

Holiday만 검색해봤다

```
target_count = '24/12/2017'
display(df_train[df_train['Date'] == target_count])
```

	Date	Rented Bike Count	Hour	Temperature(° C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(° C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
24	24/12/2017	266	0	5.6	78	0.6	196	2.0	0.00	0.0	0.0	Winter	Holiday	Yes	18106
81	24/12/2017	28	14	3.3	90	2.5	561	1.8	0.19	0.0	0.0	Winter	Holiday	Yes	12793
147	24/12/2017	38	15	2.9	90	2.0	380	1.4	0.08	3.5	0.0	Winter	Holiday	Yes	11997
562	24/12/2017	145	21	0.4	69	3.5	477	-4.6	0.00	0.0	0.0	Winter	Holiday	Yes	15627
603	24/12/2017	4	10	4.8	96	0.6	87	4.2	0.04	0.0	0.0	Winter	Holiday	Yes	12085
680	24/12/2017	79	4	5.2	82	0.7	189	2.3	0.00	0.0	0.0	Winter	Holiday	Yes	14145
1270	24/12/2017	3	9	4.6	94	0.9	90	3.7	0.00	6.4	0.0	Winter	Holiday	Yes	14408
1454	24/12/2017	251	1	5.6	78	0.5	197	2.0	0.00	0.0	0.0	Winter	Holiday	Yes	10749
2063	24/12/2017	54	16	2.3	91	3.3	270	0.9	0.07	0.0	0.0	Winter	Holiday	Yes	17498
2155	24/12/2017	116	20	0.6	67	3.3	506	-4.8	0.00	0.0	0.0	Winter	Holiday	Yes	10713
2607	24/12/2017	7	13	3.7	90	0.7	744	2.2	0.15	0.0	0.0	Winter	Holiday	Yes	15236
2625	24/12/2017	3	7	4.7	89	1.1	100	3.0	0.00	0.0	0.0	Winter	Holiday	Yes	15868
2739	24/12/2017	4	8	4.6	91	1.7	95	3.2	0.00	0.0	0.0	Winter	Holiday	Yes	16734
3116	24/12/2017	149	3	5.2	82	0.8	190	2.3	0.00	0.0	0.0	Winter	Holiday	Yes	17278
3240	24/12/2017	196	2	5.4	80	0.9	190	2.2	0.00	0.0	0.0	Winter	Holiday	Yes	15879
3915	24/12/2017	9	11	4.6	95	0.8	156	3.8	0.05	0.0	0.0	Winter	Holiday	Yes	10150
4269	24/12/2017	132	19	1.1	68	4.4	695	-4.1	0.00	0.0	0.0	Winter	Holiday	Yes	11245
4561	24/12/2017	12	6	4.9	84	1.3	159	2.4	0.00	0.1	0.0	Winter	Holiday	Yes	12027
5142	24/12/2017	44	5	5.1	82	0.6	185	2.2	0.00	0.0	0.0	Winter	Holiday	Yes	17605
5834	24/12/2017	110	22	0.2	69	2.7	565	-4.8	0.00	0.0	0.0	Winter	Holiday	Yes	14848
6856	24/12/2017	128	23	0.0	63	3.2	884	-6.2	0.00	0.0	0.0	Winter	Holiday	Yes	12266

Holiday엔 따릉이 사업을 접어도 될 것 같다

모델은 이미 Holiday를 고려하고 있었을까? 아주 쬐끔 고려하더라

다시 돌아와서, 아무 날도 아닌 평범한 평일이다

```python
# 날짜 검색 후 대여량(Rented Bike Count) 많은 순서로 정렬
target_date = '14/09/2018'
result = df_train[df_train['Date'] == target_date].sort_values(by='Rented Bike Count', ascending=False)

display(result)
```

	Date	Rented Bike Count	Hour	Temperature(˚ C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(˚ C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
481	14/09/2018	2826	18	25.7	57	1.5	2000	16.5	0.24	0.0	0.0	Autumn	No Holiday	Yes	11000
6102	14/09/2018	2253	8	21.4	70	1.5	1986	15.6	0.38	0.0	0.0	Autumn	No Holiday	Yes	15338
2842	14/09/2018	2059	17	25.9	56	1.7	2000	16.4	0.42	0.0	0.0	Autumn	No Holiday	Yes	15374
2108	14/09/2018	1996	19	25.3	60	1.2	2000	16.9	0.04	0.0	0.0	Autumn	No Holiday	Yes	15468
3991	14/09/2018	1869	20	25.0	61	1.1	2000	16.9	0.00	0.0	0.0	Autumn	No Holiday	Yes	13836
182	14/09/2018	1503	16	26.3	57	1.6	2000	17.0	0.72	0.0	0.0	Autumn	No Holiday	Yes	12567
5289	14/09/2018	1456	7	20.5	76	1.3	2000	16.1	0.06	0.0	0.0	Autumn	No Holiday	Yes	13878
1963	14/09/2018	1347	15	26.6	55	1.8	2000	16.8	1.10	0.0	0.0	Autumn	No Holiday	Yes	13287
1860	14/09/2018	1259	21	24.7	61	1.6	2000	16.6	0.00	0.0	0.0	Autumn	No Holiday	Yes	14726
991	14/09/2018	1201	9	22.3	69	1.3	2000	16.3	0.61	0.0	0.0	Autumn	No Holiday	Yes	11293
1057	14/09/2018	1199	14	26.3	58	1.5	1986	17.3	1.37	0.0	0.0	Autumn	No Holiday	Yes	18536
1766	14/09/2018	1155	13	26.4	57	1.2	2000	17.1	1.80	0.0	0.0	Autumn	No Holiday	Yes	11513
5210	14/09/2018	1088	12	25.3	56	1.2	1960	15.8	1.35	0.0	0.0	Autumn	No Holiday	Yes	12861
6696	14/09/2018	982	11	24.0	64	1.3	2000	16.7	0.95	0.0	0.0	Autumn	No Holiday	Yes	17429
2341	14/09/2018	971	0	22.1	74	1.1	1962	17.2	0.00	0.0	0.0	Autumn	No Holiday	Yes	13883
5965	14/09/2018	936	10	23.3	65	1.4	1996	16.3	0.76	0.0	0.0	Autumn	No Holiday	Yes	13060
6142	14/09/2018	810	23	22.3	87	1.1	1810	20.0	0.00	0.5	0.0	Autumn	No Holiday	Yes	15036
6384	14/09/2018	775	1	21.6	75	1.1	1671	16.9	0.00	0.0	0.0	Autumn	No Holiday	Yes	18319
3189	14/09/2018	644	6	20.4	78	1.0	2000	16.4	0.00	0.0	0.0	Autumn	No Holiday	Yes	15423
4713	14/09/2018	567	22	24.0	73	2.1	1541	18.8	0.00	0.0	0.0	Autumn	No Holiday	Yes	10602
1651	14/09/2018	482	2	21.3	75	1.1	2000	16.6	0.00	0.0	0.0	Autumn	No Holiday	Yes	18725
4618	14/09/2018	349	3	21.0	76	0.7	1995	16.6	0.00	0.0	0.0	Autumn	No Holiday	Yes	17322
4870	14/09/2018	249	5	20.7	77	0.9	2000	16.5	0.00	0.0	0.0	Autumn	No Holiday	Yes	14604
2696	14/09/2018	223	4	20.7	76	1.0	2000	16.3	0.00	0.0	0.0	Autumn	No Holiday	Yes	15844

보기 어려워서 내림차순을 해줬다

이상한 날짜 발견. 다른 토요일은 이렇지 않다.

```
# 날짜 검색 후 대여량(Rented Bike Count) 많은 순서로 정렬
target_date = '12/05/2018'
result = df_train[df_train['Date'] == target_date].sort_values(by='Rented Bike Count', ascending=False)

display(result)
```

	Date	Rented Bike Count	Hour	Temperature(˚C)	Humidity(%)	Wind speed (m/s)	Visibility (10m)	Dew point temperature(˚C)	Solar Radiation (MJ/m2)	Rainfall(mm)	Snowfall (cm)	Seasons	Holiday	Functioning Day	id
4039	12/05/2018	862	0	16.1	54	1.3	1052	6.7	0.00	0.0	0.0	Spring	No Holiday	Yes	14233
4784	12/05/2018	669	1	15.9	51	1.8	866	5.7	0.00	0.0	0.0	Spring	No Holiday	Yes	14404
3783	12/05/2018	207	4	15.0	61	0.8	867	7.5	0.00	0.0	0.0	Spring	No Holiday	Yes	12008
2423	12/05/2018	70	5	15.0	61	1.2	903	7.5	0.00	0.0	0.0	Spring	No Holiday	Yes	12852
1417	12/05/2018	50	23	15.8	98	1.6	235	15.4	0.00	1.0	0.0	Spring	No Holiday	Yes	11170
963	12/05/2018	37	6	14.4	71	1.3	560	9.2	0.00	0.4	0.0	Spring	No Holiday	Yes	18060
2419	12/05/2018	34	16	13.8	97	0.7	196	13.3	0.12	1.5	0.0	Spring	No Holiday	Yes	12195
1531	12/05/2018	29	19	15.5	97	0.7	403	15.0	0.00	2.0	0.0	Spring	No Holiday	Yes	13325
1928	12/05/2018	29	20	15.7	97	0.3	343	15.2	0.00	1.0	0.0	Spring	No Holiday	Yes	14299
3390	12/05/2018	25	21	15.8	97	0.6	193	15.3	0.00	0.5	0.0	Spring	No Holiday	Yes	11782
5567	12/05/2018	24	17	14.3	98	0.7	270	13.9	0.08	1.5	0.0	Spring	No Holiday	Yes	15359
915	12/05/2018	22	14	13.0	97	0.8	211	12.5	0.15	2.0	0.0	Spring	No Holiday	Yes	11658
3272	12/05/2018	22	18	15.4	97	1.9	340	14.9	0.03	2.0	0.0	Spring	No Holiday	Yes	11436
2816	12/05/2018	20	8	12.0	87	1.0	296	9.8	0.10	1.0	0.0	Spring	No Holiday	Yes	18282
4238	12/05/2018	19	13	12.6	97	0.6	327	12.1	0.14	3.0	0.0	Spring	No Holiday	Yes	10645
3152	12/05/2018	18	11	12.0	96	1.0	184	11.3	0.14	3.5	0.0	Spring	No Holiday	Yes	11454
1268	12/05/2018	17	15	13.3	97	0.8	194	12.8	0.12	3.0	0.0	Spring	No Holiday	Yes	12946
4237	12/05/2018	16	9	11.8	95	1.0	168	11.0	0.14	3.0	0.0	Spring	No Holiday	Yes	18250
1930	12/05/2018	11	12	12.3	97	0.8	238	11.8	0.14	2.0	0.0	Spring	No Holiday	Yes	12574
2012	12/05/2018	6	10	11.8	96	1.3	221	11.1	0.12	2.5	0.0	Spring	No Holiday	Yes	13896

따릉이 전체 중에 10의 자리수로만 빌렸다고?

가시거리가 매우 낮기 때문이다.

나머진 원래대로 돌리고 낮은 가시거리만 추가해봤다

```
# 2. 가시성 임계값 (가시거리 10m 단위 기준, 4000m(400) 이하를 저시정으로 판단)
# 데이터셋의 Visibility 단위를 확인하세요 (보통 20000이 최대값인 경우 400 미만을 추천)
df['Low_Visibility'] = (df['Visibility (10m)'] < 400).astype(int)
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 244.053
R2: 0.854
--------------------------------
Random Forest
RMSE: 173.421
R2: 0.926
--------------------------------
XGBoost
RMSE: 150.177
R2: 0.945
--------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 244.645
R2: 0.853
--------------------------------
Random Forest
RMSE: 176.800
R2: 0.923
--------------------------------
XGBoost
RMSE: 149.581
R2: 0.945
--------------------------------
```

RMSE가 아주 약간 좋아지긴 했다

이번엔 시간대를 추가해봤다

```python
# 1. 시간대 다중 플래그 (중첩 허용)
df_fe['Time_Night'] = df_fe['Hour'].between(22, 23) | df_fe['Hour'].between(0, 6) # 안 빌리는 시간
df_fe['Time_Commute'] = ((df_fe['weekend'] == 0) & df_fe['Hour'].isin([8, 17, 18, 19])).astype(int)
df_fe['Time_Weekend_Peak'] = ((df_fe['weekend'] == 1) & df_fe['Hour'].isin([15, 16, 17, 18, 19])).astype(int)

# 3. 10의 자리 vs 1의 자리 패턴 (사용자 가설 반영)
# 10~21시 사이의 활성 시간대 강조
df_fe['Time_Active_Range'] = df_fe['Hour'].between(7, 21).astype(int)
```

Time_Night	Time_Commute	Time_Weekend_Peak	Time_Active_Range
False	0	0	1
True	0	0	0
True	0	0	0
False	0	0	1
False	0	0	1

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 244.645
R2: 0.853
--------------------------------
Random Forest
RMSE: 176.800
R2: 0.923
--------------------------------
XGBoost
RMSE: 149.581
R2: 0.945
--------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 251.084
R2: 0.846
--------------------------------
Random Forest
RMSE: 177.108
R2: 0.923
--------------------------------
XGBoost
RMSE: 151.766
R2: 0.944
--------------------------------
```

아아... 오차가 증가했다

(참고로 Hour를 그냥 drop 하니까 오차가 눈 뜨고 봐줄 수 없을 정도가 되어서 복구)

Seasons를 학습하는 거에 비해 너무 적게 사용해서, 온도만 따지게끔 계절을 없애 보았다

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 251.084
R2: 0.846
------------------------------
Random Forest
RMSE: 177.108
R2: 0.923
------------------------------
XGBoost
RMSE: 151.766
R2: 0.944
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 242.421
R2: 0.856
------------------------------
Random Forest
RMSE: 180.242
R2: 0.920
------------------------------
XGBoost
RMSE: 152.633
R2: 0.943
------------------------------
```

생각보다 지대한 영향을 주진 않는 것 같다

Scree Plot도 변수명이 나오도록 해봤다

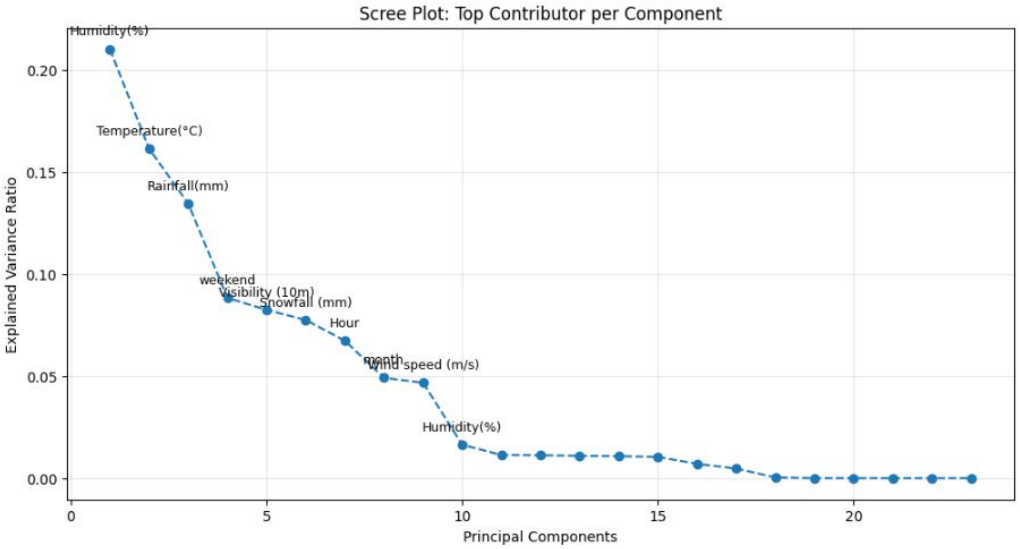


```python
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
import numpy as np

# 1. PCA 실행
pca = PCA()
pca.fit(X_tr_EDA)

# 2. 각 주성분(PC)별로 가장 영향력이 큰(절대값 기준) 원본 변수 찾기
# pca.components_ 는 (주성분 개수, 원본 변수 개수) 형태입니다.
feature_names = X_tr_EDA.columns
top_features = [feature_names[np.argmax(np.abs(pc))] for pc in pca.components_]

# 3. 시각화
plt.figure(figsize=(12, 6))
x_range = range(1, len(pca.explained_variance_ratio_) + 1)
plt.plot(x_range, pca.explained_variance_ratio_, marker='o', linestyle='--')

# 4. 점 위에 가장 기여도가 높은 변수 이름 표시 (Annotation)
for i, txt in enumerate(top_features):
    # 정보량이 너무 적은 뒷부분은 생략하고 상위 몇 개만 표시하는 것이 가독성에 좋습니다.
    if i < 7: # 상위 7개 성분만 이름 표시 (인지 부하 감소)
        plt.annotate(txt, (x_range[i], pca.explained_variance_ratio_[i]),
                     textcoords="offset points", xytext=(0,10), ha='center', fontsize=9)

plt.title('Scree Plot: Top Contributor per Component')
plt.xlabel('Principal Components')
plt.ylabel('Explained Variance Ratio')
plt.grid(True, alpha=0.3)
plt.show()
```

잉? 근데 Humidity가 높다. 그리고 하나가 더 있다 (?)
그리고 완만하다
우선 습도를 기준으로 칼럼을 만들어 보자

해봤다

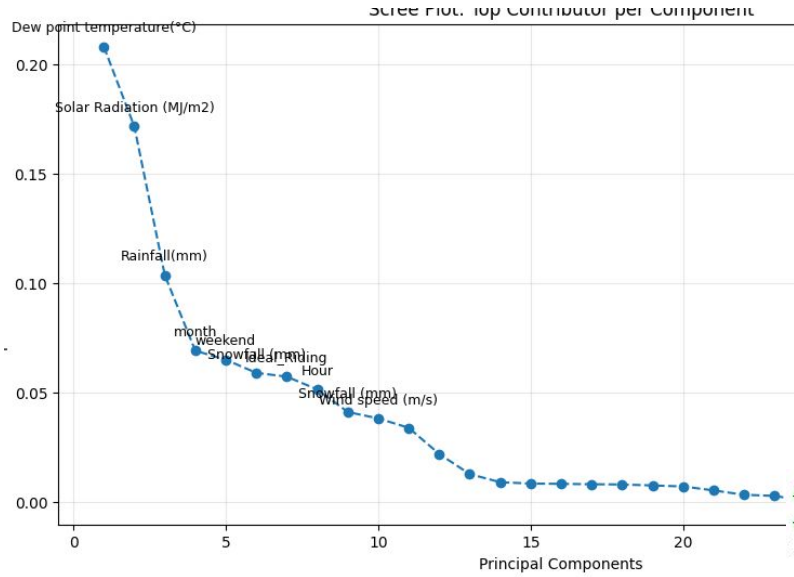


```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 242.421
R2: 0.856
------------------------------
Random Forest
RMSE: 180.242
R2: 0.920
------------------------------
XGBoost
RMSE: 152.633
R2: 0.943
------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
------------------------------
EDA
Decision Tree
RMSE: 251.516
R2: 0.845
------------------------------
Random Forest
RMSE: 177.738
R2: 0.923
------------------------------
XGBoost
RMSE: 151.338
R2: 0.944
------------------------------
```

```python
# 1. 불쾌지수 (Discomfort Index)
# 80 이상: 매우 불쾌, 75~80: 50% 불쾌, 68~75: 불쾌 시작
df_fe['Discomfort_Index'] = (1.8 * df_fe['Temperature(° C)'] + 32) - ₩
  (0.55 - 0.0055 * df_fe['Humidity(%)']) * ₩
  (1.8 * df_fe['Temperature(° C)'] - 26)

# 2. 고습도 플래그 (비 오기 직전이나 끈적이는 상태)
# 습도가 80% 이상일 때 1, 아니면 0
df_fe['Is_Steamy'] = (df_fe['Humidity(%)'] >= 80).astype(int)

# 3. 쾌적 라이딩 지수 (기온 15~25도 사이 & 습도 30~60% 사이)
# 가장 자전거 타기 좋은 '골디락스' 날씨 여부
df_fe['Ideal_Riding'] = ((df_fe['Temperature(° C)'].between(15, 25)) & (df_fe['Humidity(%)'].between(30, 60))).as

# 4. 건조 지수 (습도 30% 미만일 때 화재 위험 및 호흡기 불편함 반영)
df_fe['Is_Dry'] = (df_fe['Humidity(%)'] < 30).astype(int)
```

오차가 뭐 미세하게 내린 것 같고,
그래프가 모양이 좀 바뀌었다

좀더 팔꿈치 같아졌다

몇 개 더 추가했다

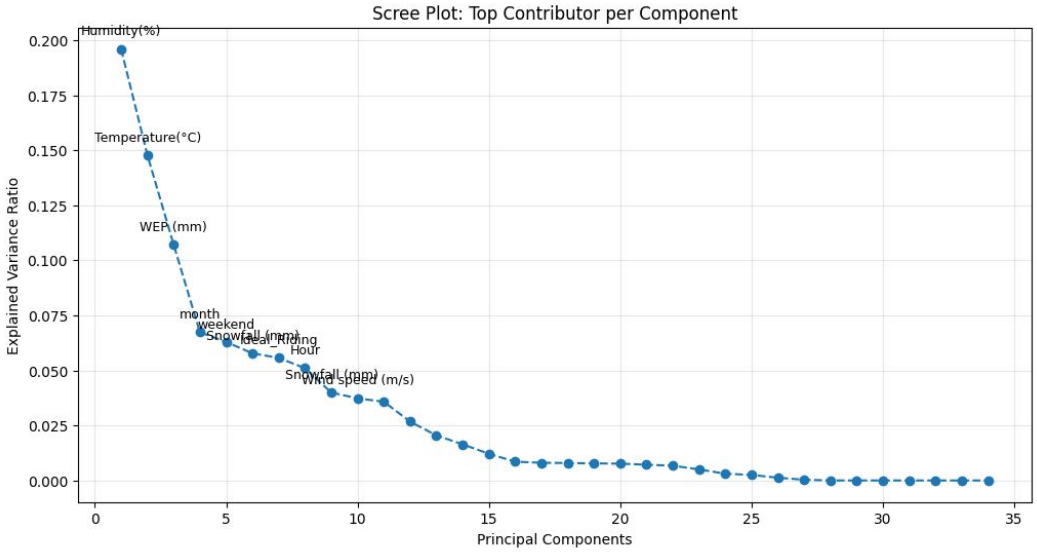


```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 251.516
R2: 0.845
--------------------------------
Random Forest
RMSE: 177.738
R2: 0.923
--------------------------------
XGBoost
RMSE: 151.338
R2: 0.944
--------------------------------
```

```
basic
Decision Tree
RMSE: 324.027
R2: 0.743
--------------------------------
Random Forest
RMSE: 240.347
R2: 0.859
--------------------------------
XGBoost
RMSE: 227.370
R2: 0.873
--------------------------------
EDA
Decision Tree
RMSE: 247.137
R2: 0.850
--------------------------------
Random Forest
RMSE: 174.067
R2: 0.926
--------------------------------
XGBoost
RMSE: 151.895
R2: 0.943
--------------------------------
```

에이 모르겠다

```
# 이슬점 온도 드랍
df_fe.drop(columns=['Dew point temperature(° C)'], inplace=True)

# 비가 오냐?
df_fe['Is_Raining'] = (df_fe['Rainfall(mm)'] > 0).astype(int)

# 자외선 컷
df_fe['Sunlight_Level'] = pd.cut(df_fe['Solar Radiation (MJ/m2)'], bins=[-1, 0.1, 2, 10], labels=[0, 1, 2])
```